

PROJECT METODE PERAMALAN
ANALISIS PERAMALAN HARGA EMAS DENGAN PENDEKATAN
ARIMA-GARCH DI INDONESIA



Anggota Kelompok:

Dastin Rangga Berani	(2306231776)
Muhammad Binar Raffi Lazuardi	(2306228005)
Taslim Ismail Anshorullah	(2306249666)
Franklin Daniel Situmorang	(2306201174)

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS INDONESIA
ATA 2024/2025

DAFTAR ISI

DAFTAR ISI	iii
BAB 1 PENDAHULUAN.....	4
1.1. Latar Belakang.....	4
1.2. Rumusan Masalah.....	5
1.3. Tujuan	5
BAB 2 LANDASAN TEORI.....	6
2.1. <i>Time Series Forecasting</i>	6
2.2. Model ARIMA	6
2.2.1. Generalized ARMA (p,q)	7
2.3. Model GARCH.....	8
2.3.1. Model GARCH (m,s)	8
2.4. Model <i>Hybrid</i> ARIMA-GARCH.....	9
2.5. Transformasi Data	9
2.5.1. Transformasi Logaritma	10
2.6. Uji Stasioneritas (Uji Augmented Dickey-Fuller / ADF).....	11
2.7. Analisis Autokorelasi (ACF dan PACF)	11
2.8. Lagrange Multiplier Test / ARCH-LM Test.....	12
2.9. Uji Ljung-Box.....	12
BAB 3 DESKRIPSI DATA DAN EVDA	13
3.1. Deskripsi Data	13
3.2. Pra-Pengolahan Data	13
3.2.1. Pengecekan Tipe Data	13
3.2.2. Pengecekan Nilai Kosong.....	14
BAB 4 Pembahasan	16
4.1. Pemodelan ARIMA	16
4.1.1. Uji ADF	16
4.1.2. Uji KPSS.....	16
4.2. Pemodelan GARCH	23
BAB 5 Kesimpulan	32
5.1. Kesimpulan	32
DAFTAR PUSTAKA	33

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Harga emas memiliki peranan penting dalam perekonomian Indonesia, baik sebagai instrumen investasi, cadangan devisa negara, maupun sebagai indikator kestabilan ekonomi. Sebagai salah satu komoditas yang paling diminati, pergerakan harga emas sangat dipengaruhi oleh berbagai faktor ekonomi global dan domestik, seperti nilai tukar, inflasi, tingkat suku bunga, serta ketidakpastian geopolitik. Di tengah ketidakpastian ekonomi yang kerap terjadi, kemampuan untuk meramalkan harga emas menjadi sangat krusial bagi investor, pemerintah, dan pelaku pasar lainnya dalam mengambil keputusan strategis. Namun, pergerakan harga emas cenderung bersifat non-linear, fluktuatif, dan mengandung volatilitas tinggi yang tidak dapat dijelaskan secara akurat hanya dengan model linier tradisional. Oleh karena itu, dibutuhkan pendekatan peramalan yang mampu menangkap pola musiman, tren, serta dinamika volatilitas dari data deret waktu harga emas.

Model ARIMA (*Autoregressive Integrated Moving Average*) dikenal efektif dalam menangkap pola linier dalam data deret waktu, seperti tren dan autokorelasi jangka pendek. Sementara itu, model GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*) dirancang untuk menangani perubahan volatilitas yang sering muncul dalam data keuangan, termasuk harga emas. Dengan menggabungkan kedua model ini menjadi pendekatan ARIMA-GARCH, diharapkan hasil peramalan harga emas menjadi lebih akurat dan mencerminkan karakteristik sebenarnya dari data. Penelitian mengenai peramalan harga emas dengan pendekatan ARIMA-GARCH di Indonesia masih relatif terbatas, padahal kebutuhan terhadap akurasi prediksi sangat tinggi, terutama dalam menghadapi dinamika pasar global yang cepat berubah. Dengan demikian, studi ini penting untuk memberikan kontribusi dalam bidang ekonomi dan keuangan, khususnya dalam meningkatkan efektivitas pengambilan keputusan berbasis data di sektor investasi emas di Indonesia.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dikemukakan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana pola pergerakan dan volatilitas harga emas di Indonesia dapat dianalisis secara statistik menggunakan model ARIMA-GARCH?
2. Bagaimana spesifikasi model ARIMA-GARCH yang sesuai dengan data harga emas di Indonesia?

1.3. Tujuan

Tujuan dari penelitian ini adalah

1. Membangun model peramalan harga emas dengan pendekatan ARIMA-GARCH guna menangkap pola linier dan volatilitas data secara simultan.
2. Melakukan spesifikasi model ARIMA-GARCH dengan parameter yang sesuai.

BAB 2

LANDASAN TEORI

2.1. *Time Series Forecasting*

Time series forecasting adalah bidang esensial dalam analisis statistik dan ekonometri yang bertujuan untuk memprediksi nilai masa depan dari suatu deret waktu berdasarkan nilai-nilai historisnya (Navaei, 2023). Dalam ranah ini, dua model fundamental yang sering digunakan adalah ARIMA (*Autoregressive Integrated Moving Average*) dan GARCH (*Generalized Autoregressive Conditional Heteroscedasticity*). ARIMA adalah model statistik yang efektif untuk menggambarkan dan memprediksi autokorelasi dalam *mean* data deret waktu, sementara GARCH dirancang khusus untuk memodelkan *volatility clustering* atau perubahan varians bersyarat yang tidak konstan dari waktu ke waktu, terutama umum dalam data keuangan.

Seiring perkembangan kebutuhan akan prediksi yang lebih akurat dan komprehensif, muncul pendekatan *hybrid* yang menggabungkan kekuatan kedua model ini. Laporan ini akan membahas secara mendalam model ARIMA dan GARCH, mengidentifikasi perbedaan kunci di antara keduanya, mengeksplorasi kekuatan dan kelemahannya, serta menguraikan kondisi penggunaan yang sesuai. Selain itu, akan diperkenalkan pula konsep model *hybrid* ARIMA-GARCH yang seringkali memberikan performa superior dalam peramalan deret waktu yang kompleks seperti harga saham dan komoditas ([Mutiara, 2022](#)).

2.2. **Model ARIMA**

Model ARIMA adalah model deret waktu linier yang populer dan fleksibel, digunakan untuk peramalan berdasarkan data deret waktu tunggal (univariat). Model ini terdiri dari tiga komponen utama:

1. *Autoregresi* (AR): Bagian ini memodelkan hubungan antara observasi saat ini (Y_t) dengan observasi sebelumnya yang *lagged* (Y_{t-1}). Orde p menunjukkan jumlah *lagged observations* yang digunakan.
2. *Differencing* (I): Komponen "Integrated" ini mengacu pada proses *differencing* data deret waktu untuk membuatnya menjadi stasioner. Stasioneritas adalah asumsi fundamental dalam model ARIMA, di mana *mean*, varians, dan

autokorelasi deret waktu tidak berubah seiring waktu. Orde d menunjukkan berapa kali proses *differencing* dilakukan.

3. *Moving Average* (MA): Bagian ini memodelkan ketergantungan antara observasi saat ini dan *error term* dari observasi sebelumnya yang *lagged* (ϵ_{t-j}). Orde q menunjukkan jumlah *lagged error terms* yang digunakan.

Model ARIMA sangat fleksibel dan dapat menangani berbagai pola data deret waktu, termasuk tren dan musiman, setelah proses *differencing* yang tepat.

2.2.1. Generalized ARMA (p,q)

Sebelum memahami ARIMA secara penuh, konsep model ARMA (*Autoregressive Moving Average*) merupakan dasar penting. Model ARMA(p,q) adalah kombinasi dari model Autoregresi (AR) orde p dan *Moving Average* (MA) orde q yang diterapkan pada deret waktu yang sudah stasioner. Persamaan umum untuk model ARMA(p,q) dapat ditulis sebagai:

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

Di mana:

- Y_t adalah nilai deret waktu pada waktu t
- c adalah konstanta
- ϕ_i adalah koefisien autoregresif untuk *lag* i
- ϵ_t adalah *error term* pada waktu t (sering diasumsikan sebagai *white noise*)
- θ_j adalah koefisien *moving average* untuk *lag* j
- p adalah orde AR
- q adalah orde MA

Model ARIMA(p,d,q) pada dasarnya adalah model ARMA(p,q) yang diterapkan pada data yang telah di-*differencing* sebanyak d kali pada Y_t . untuk mendapatkan deret waktu stasioner Y'_t , lalu menerapkan model ARMA(p,q) pada Y'_t :

$$Y'_t = c + \sum_{i=1}^p \phi_i Y'_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

Di mana Y'_t adalah deret waktu setelah *differencing*. Model ARIMA telah banyak diterapkan dalam peramalan harga komoditas, seperti harga emas ([Nugraha et al., 2021](#)),

dan bahkan inflasi ([Mutiarra, 2022](#)). Contoh spesifik aplikasi adalah model ARIMA(0,1,1) untuk peramalan harga emas di Indonesia ([Situmorang, 2017](#)).

2.3. Model GARCH

Model GARCH (*Generalized Autoregressive Conditional Heteroscedasticity*) adalah model deret waktu yang secara spesifik dirancang untuk memodelkan volatility clustering, fenomena umum pada data keuangan di mana periode volatilitas tinggi cenderung diikuti oleh periode volatilitas tinggi, dan sebaliknya. Model ini penting karena varians *error term* pada data keuangan seringkali tidak konstan (heteroskedastisitas).

Model GARCH adalah pengembangan dari model ARCH (Autoregressive Conditional Heteroscedasticity) yang diperkenalkan oleh Engle (1982). Model GARCH(p,q) terdiri dari dua bagian utama:

1. *ARCH Part*: Bagian ini memodelkan varians bersyarat dari *error term* sebagai fungsi dari *squared error* masa lalu.
2. *GARCH Part*: Bagian ini memodelkan varians bersyarat saat ini sebagai fungsi dari varians bersyarat masa lalu.

Berikut adalah ilustrasi model GARCH(P,Q) dan penurunan formulasi GARCH(1,1) dari model ARCH(p) dengan struktur *lag* geometris:

2.3.1. Model GARCH (m,s)

Model GARCH memodifikasi model ARCH(q) dengan memberlakukan struktur *lag* geometris, seringkali dalam bentuk:

$$b_s = b_1 \theta^{s-1}$$

Persamaan varians bersyarat h_t awalnya dapat ditulis sebagai:

$$h_t = b_0 + b_1 u_{t-1}^2 + \theta_1 b_1 u_{t-2}^2 + \theta_1^2 b_1 u_{t-3}^2 + \dots$$

Dengan menambahkan dan mengurangi $\theta_1 b_0$ serta menata ulang suku-suku, kita mendapatkan:

$$h_t = (b_0 - \theta_1 b_0) + \theta_1 (b_0 + b_1 u_{t-2}^2 + \theta_1 b_1 u_{t-3}^2 + \dots) + b_1 u_{t-1}^2$$

Mengingat bahwa $h_{t-1} = b_0 + b_1 u_{t-2}^2 + \theta_1 b_1 u_{t-3}^2 + \dots + b_1 u_{t-2}^2$, persamaan ini dapat disederhanakan menjadi:

$$h_t = \varphi + \theta_1 h_{t-1} + b_1 u_{t-1}^2$$

Di mana, $\varphi = (b_0 - \theta_1 b_0)$.

Ini adalah representasi dari model GARCH(1,1): model ini mengandung 1 suku *lagged* dari varians bersyarat (h) dan 1 suku *lagged* dari *squared error* (u^2). Ini menunjukkan bahwa varians saat ini tidak hanya bergantung pada *squared error* sebelumnya, tetapi juga pada varians bersyarat periode sebelumnya, menangkap efek memori dalam volatilitas. Model GARCH sangat luas digunakan dalam pemodelan keuangan, terutama untuk harga saham dan volatilitas.

2.4. Model *Hybrid* ARIMA-GARCH

Untuk deret waktu keuangan seperti harga emas, yang sering menunjukkan baik autokorelasi pada *mean* maupun *volatility clustering* pada varians, pendekatan model tunggal mungkin tidak memadai. Oleh karena itu, model *hybrid* ARIMA-GARCH menjadi pilihan yang lebih komprehensif dan efektif. Pendekatan ini biasanya melibatkan dua tahap:

1. Pemodelan *Mean* dengan ARIMA: Model ARIMA diterapkan pada deret waktu *return* (atau harga yang telah distasionerkan) untuk menangkap struktur linier dan memodelkan *meannya*. Tujuan dari tahap ini adalah untuk menghasilkan *residual* yang diharapkan berupa *white noise* dalam *meannya*, tetapi mungkin masih menunjukkan heteroskedastisitas.
2. Pemodelan Varians dengan GARCH: Model GARCH (atau variannya seperti TGARCH) kemudian diterapkan pada *squared residual* yang diperoleh dari model ARIMA tahap pertama. Ini bertujuan untuk memodelkan dan memprediksi dinamika volatilitas yang terkandung dalam *residual* tersebut.

Penggabungan kedua model ini memungkinkan prediksi yang lebih akurat karena mampu menangkap karakteristik deret waktu yang kompleks secara menyeluruh, baik pada bagian *mean* maupun variansnya ([Situmorang, 2017](#)). Berbagai studi telah membuktikan keefektifan model *hybrid* ini dalam peramalan harga saham ([Dela Cruz, 2019](#)).

2.5. Transformasi Data

Sebelum melakukan pemodelan deret waktu, data seringkali perlu ditransformasi untuk memenuhi asumsi tertentu dari model statistik atau untuk meningkatkan kinerja model. Tujuan utama transformasi data adalah untuk membuat data lebih sesuai dengan

asumsi yang mendasari teknik statistik yang akan digunakan, seperti stasioneritas, normalitas, atau homoskedastisitas (varians konstan). Tanpa transformasi yang tepat, hasil analisis dan peramalan dapat menjadi bias atau tidak akurat. Beberapa tujuan umum dari transformasi data meliputi:

- Menstabilkan Varians: Mengatasi masalah heteroskedastisitas di mana varians deret waktu tidak konstan sepanjang waktu.
- Mencapai Normalitas: Membuat distribusi data lebih mendekati distribusi normal, yang merupakan asumsi untuk banyak metode statistik.
- Linearisasi Hubungan: Mengubah hubungan non-linier antar variabel menjadi lebih linier.
- Mengurangi Pengaruh *Outlier*: Meminimalkan dampak nilai-nilai ekstrem pada analisis.

2.5.1. Transformasi Logaritma

Salah satu bentuk transformasi data yang paling umum dan efektif, khususnya untuk data keuangan seperti harga emas, adalah transformasi logaritma natural ($\ln$), yang sering disingkat sebagai transformasi log. Transformasi ini sangat berguna ketika data menunjukkan pola pertumbuhan eksponensial atau ketika variansnya meningkat seiring dengan *mean*-nya. Transformasi log membantu:

- Menstabilkan Varians: Harga-harga yang meningkat secara eksponensial sering memiliki varians yang juga meningkat seiring dengan *mean*-nya. Transformasi logaritma dapat mengubah hubungan ini menjadi lebih linier, sehingga variansnya menjadi lebih stabil atau konstan. Hal ini penting untuk memenuhi asumsi homoskedastisitas pada banyak model deret waktu.
- Mengubah Distribusi: Data harga yang cenderung memiliki distribusi *right-skewed* (condong ke kanan) dapat menjadi lebih simetris atau mendekati distribusi normal setelah transformasi logaritma.
- Memfasilitasi Perhitungan *Log Return*: Seperti yang dijelaskan sebelumnya, transformasi logaritma adalah dasar untuk menghitung *log*

return, yang merupakan data yang lebih cocok untuk pemodelan volatilitas karena sifat aditifnya ([Nugraha et al., 2021](#)).

Misalnya, *log return* R_t dari harga P_t pada waktu t dihitung sebagai $R_t = \ln(P_t / P_{t-1})$.

2.6. Uji Stasioneritas (Uji Augmented Dickey-Fuller / ADF)

Stasioneritas adalah asumsi fundamental untuk sebagian besar model deret waktu, termasuk ARIMA. Deret waktu dikatakan stasioner jika *mean*, *varians*, dan *autokorelasi* tidak berubah seiring waktu. Jika suatu deret waktu tidak stasioner, hasil peramalan dapat menjadi bias atau tidak valid.

Salah satu metode yang paling sering digunakan untuk menguji stasioneritas adalah Uji *Augmented Dickey-Fuller* (ADF). Uji ADF menguji hipotesis nol (H_0) bahwa deret waktu memiliki *unit root* (non-stasioner) terhadap hipotesis alternatif (H_1) bahwa deret waktu tidak memiliki *unit root* (stasioner). Jika nilai p-value dari uji ADF lebih kecil dari tingkat signifikansi yang ditentukan, maka hipotesis nol ditolak, dan deret waktu dianggap stasioner. Jika deret waktu tidak stasioner, proses *differencing* perlu dilakukan hingga deret waktu menjadi stasioner.

2.7. Analisis Autokorelasi (ACF dan PACF)

Setelah deret waktu dipastikan stasioner, langkah selanjutnya dalam identifikasi model ARIMA adalah menganalisis fungsi autokorelasi (ACF) dan fungsi autokorelasi parsial (PACF). Kedua plot ini membantu dalam menentukan orde p (AR) dan q (MA) dari model ARIMA.

- Fungsi Autokorelasi (ACF): Mengukur korelasi antara suatu observasi dan observasi sebelumnya pada *lag* tertentu, termasuk efek tidak langsung dari *lag* di antaranya. Plot ACF menunjukkan nilai koefisien autokorelasi pada berbagai *lag*. Untuk model MA(q), plot ACF akan *cut off* (jatuh ke nol secara signifikan) setelah *lag* q .
- Fungsi Autokorelasi Parsial (PACF): Mengukur korelasi antara suatu observasi dan observasi sebelumnya pada *lag* tertentu, setelah menghilangkan efek dari *lag* di antaranya. Plot PACF menunjukkan nilai koefisien autokorelasi parsial pada berbagai *lag*. Untuk model AR(p), plot PACF akan *cut off* setelah *lag* p .

Pola *cut off* pada ACF dan PACF ini menjadi panduan penting dalam menentukan orde p dan q yang potensial untuk model ARIMA ([Nugraha et al., 2021](#)).

2.8. Lagrange Multiplier Test / ARCH-LM Test

Setelah model ARIMA diestimasi dan *residual* diperoleh, penting untuk memeriksa apakah residual tersebut menunjukkan sifat heteroskedastisitas, yaitu varians yang tidak konstan seiring waktu. Kehadiran heteroskedastisitas, khususnya *volatility clustering*, mengindikasikan bahwa model GARCH mungkin diperlukan untuk memodelkan varians residual tersebut.

Salah satu uji statistik yang umum digunakan untuk mendeteksi *volatility clustering* adalah *Lagrange Multiplier Test* (LM Test), yang sering juga disebut ARCH-LM Test. Uji ini menguji hipotesis nol (H_0) bahwa tidak ada efek ARCH/GARCH dalam residual (yaitu, varians konstan) terhadap hipotesis alternatif (H_1) bahwa ada efek ARCH/GARCH (yaitu, ada *volatility clustering*). Jika nilai p-value dari uji ini lebih kecil dari tingkat signifikansi yang ditentukan, maka H_0 ditolak, menunjukkan adanya heteroskedastisitas dan perlunya model GARCH.

2.9. Uji Ljung-Box

Setelah model ARIMA-GARCH diestimasi, penting untuk melakukan pengujian diagnostik pada *residual* standar dari model. Tujuan utama dari pengujian ini adalah untuk memastikan bahwa model yang dibangun telah menangkap semua informasi yang relevan dari deret waktu dan *residual* yang tersisa tidak lagi menunjukkan pola sistematis.

Uji Ljung-Box (juga dikenal sebagai Uji Portmanteau) adalah uji statistik yang digunakan untuk memeriksa apakah ada autokorelasi yang signifikan dalam *residual* pada berbagai *lag*. Hipotesis nol (H_0) dari uji Ljung-Box adalah bahwa *residual* bersifat independen (tidak ada autokorelasi). Jika nilai p-value dari uji Ljung-Box lebih besar dari tingkat signifikansi yang ditentukan, maka H_0 tidak ditolak, yang menunjukkan bahwa *residual* sudah bersifat *white noise* (tidak ada pola autokorelasi yang signifikan), dan model yang diestimasi sudah memadai. Sebaliknya, jika p-value kecil, maka ada autokorelasi yang tersisa, yang mengindikasikan bahwa model perlu disempurnakan.

BAB 3

DESKRIPSI DATA DAN EVDA

3.1. Deskripsi Data

Data yang digunakan dalam penelitian ini diperoleh dari situs *investing.com*, yang menyajikan data historis nilai tukar mata uang GAU terhadap IDR selama tiga tahun terakhir. Dataset terdiri dari 838 entri dengan tujuh kolom, termasuk tanggal, nilai terakhir, pembukaan, tertinggi, terendah, volume, dan perubahan persentase. Seluruh kolom kecuali volume memiliki nilai non-null, tetapi semua kolom selain volume masih bertipe data objek, termasuk kolom tanggal yang seharusnya bertipe *datetime*. Kolom volume bahkan tidak memiliki satu pun nilai valid (semua *null*). Keadaan ini mengindikasikan perlunya tahap praproses data, termasuk konversi tipe data, penanganan nilai hilang, serta penyesuaian struktur data agar siap untuk dianalisis lebih lanjut.

3.2. Pra-Pengolahan Data

3.2.1. Pengecekan Tipe Data

Sebelum melakukan pemodelan, perlu dipastikan dahulu bahwa data yang dimiliki sudah dalam bentuk dan format yang tepat agar dapat dianalisis lebih lanjut. Pertama, akan dicek tipe data dari setiap kolom. Hasilnya sebagai berikut.

```

#   Column      Non-Null Count  Dtype
---  -
0   Tanggal     838 non-null    object
1   Terakhir    838 non-null    object
2   Pembukaan   838 non-null    object
3   Tertinggi    838 non-null    object
4   Terendah     838 non-null    object
5   Vol.         0 non-null      float64
6   Perubahan%   838 non-null    object
dtypes: float64(1), object(6)
memory usage: 46.0+ KB

```

Gambar 3.1. Pengecekan Tipe Data


Sumber: Lampiran 1

Berdasarkan *output* di atas, diketahui bahwa terdapat kolom yang belum dalam tipe yang tepat, yakni ‘Tanggal’. ‘Terakhir’, ‘Pembukaan’, ‘Tertinggi’, ‘Terendah’, dan ‘Perubahan%’. Selain itu, juga diketahui bahwa kolom ‘Vol.’ hanya berisikan nilai kosong. Pada proyek ini, kolom yang diperlukan hanyalah

kolom ‘Tanggal’ dan ‘Terakhir’. Oleh karena itu, kolom ‘Tanggal’ dan ‘Terakhir’ akan dipertahankan, sedangkan kolom lainnya akan dibuang. Karena kolom ‘Tanggal’ informasi waktu, maka tipe data akan diubah ke ‘*datetime*’. Adapun kolom ‘Terakhir’ akan diubah ke tipe data ‘*float*’ karena berisikan informasi numerik berupa harga penutupan emas di hari terkait.

3.2.2. Pengecekan Nilai Kosong


Salah satu aspek penting yang perlu diperhatikan dalam data deret waktu adalah bahwa jarak waktu tiap baris haruslah sama. Oleh karena itu, data deret waktu yang dimiliki akan dikenakan *upsampling* dari *weekly* ke *daily* sedemikian sehingga jarak waktu tiap baris konsisten, yakni dalam interval hari. Berikut adalah plot deret waktu setelah dilakukan *upsampling*.



Gambar 3.2. Visualisasi Data Setelah *Upsampling* ke Data Harian

Sumber: Lampiran 1

Dapat diperhatikan bahwa terdapat nilai kosong pada beberapa titik waktu. Dalam hal ini, jumlah nilai kosong pada data setelah dikenakan *upsampling* adalah sebanyak 258. Strategi imputasi nilai kosong yang dilakukan adalah: *rolling mean* 7 hari, *rolling mean* 30 hari, interpolasi linear, dan *shifting*. Metode tersebut sudah ditulis dengan memperhatikan urutan. Dengan kata lain, jika satu metode tidak berhasil mengimputasi seluruh data, maka akan dilanjutkan dengan metode imputasi berikutnya. Setelah dilakukan imputasi, data deret waktu akan seperti berikut.



Gambar 3.3. Visualisasi Data Setelah Imputasi

Sumber: Lampiran 1

Dapat diperhatikan bahwa pada Gambar 3.3 nilai yang hilang sudah teratasi dengan baik dan data siap untuk dianalisis.

BAB 4

PEMBAHASAN

4.1. Pemodelan ARIMA

Dalam memperoleh model ARIMA, tahap awal yang dilakukan adalah melihat kestasioneran data. Kestasioneran data akan dicek melalui uji ADF dan uji KPSS. Berikut adalah detail dari pengecekan tersebut.

4.1.1. Uji ADF

Uji ADF berfungsi untuk menguji apakah deret waktu memiliki akar unit (*unit root*), yang merupakan indikator bahwa deret waktu tidak stasioner. Untuk itu, hipotesis dari uji ADF, yakni:

$$H_0: \text{Random Walk}$$

$$H_1: \text{Stasioner}$$

Aturan keputusannya, H_0 ditolak jika $p\text{-value} < \alpha = 0.05$. Untuk mempermudah, pengujian akan dilakukan dengan bantuan *software python* dengan hasil sebagai berikut.

Tabel 4.1. Hasil Uji KPSS

Statistik Uji	<i>p-value</i>
1,5956	0,998

Sumber: Lampiran 1

Dari hasil di atas, diperoleh $p\text{-value} = 0.99 > 0.05$. Oleh karena itu, H_0 ditolak yang berarti deret waktu yang dipunyai tidak stasioner.

4.1.2. Uji KPSS

Uji KPSS berfungsi untuk menguji apakah deret waktu stasioner di sekitar level atau tren deterministik. Uji ini memang sering digunakan sebagai pelengkap uji ADF. Untuk itu, hipotesis dari uji KPSS adalah sebagai berikut.

$$H_0: \text{Stasioner}$$

$$H_1: \text{Random Walk}$$

Aturan keputusannya, H_0 ditolak jika $p\text{-value} < \alpha = 0.05$. Untuk mempermudah, pengujian akan dilakukan dengan bantuan *software python* dengan hasil sebagai berikut.


Tabel 4.2. Hasil Uji KPPS

Statistik Uji	<i>p-value</i>
4,6713	0,01

Sumber: Lampiran 1

Dari hasil di atas, diperoleh $p\text{-value} = 0.01 < 0.05$. Oleh karena itu, H_0 gagal ditolak yang berarti deret waktu yang dipunyai tidak stasioner.

Dari kedua uji di atas, maka dapat disimpulkan bahwa deret waktu yang dipunyai tidak stasioner. Untuk itu, selanjutnya perlu diperiksa asumsi stasioneritas yang dilanggar. Stasioneritas dalam mean akan diperiksa menggunakan plot data. Sedangkan, stasioneritas dalam varians akan diperiksa menggunakan Uji *White*.




Gambar 4.1. Visualisasi Mean dan Variansi dari Data Asli

Sumber: Lampiran 1

Melalui plot di atas, cukup jelas bahwa terdapat tren naik dalam jangka panjang. Artinya, asumsi mean konstan telah terlanggar.


Dari pengujian sebelumnya, telah diketahui bahwa deret waktu yang ada tidak stasioner dalam mean. Dengan demikian, perlu dilakukan diferensiasi pada data.

Gambar 4.2. Hasil *Differencing* pada Data Asli

Sumber: Lampiran 1

Gambar di atas menunjukkan plot deret waktu (sebelum serta sesudah differensiasi sekali dan dua kali) beserta dengan plot ACF-nya. Dapat diperhatikan, differensiasi orde pertama sudah cukup untuk membuat deret waktu memiliki mean yang terlihat konstan (tidak ada tren naik). Untuk melihat apakah deret waktu sudah stasioner secara statistik, maka akan dilakukan kembali uji ADF dan uji KPPS dengan hasil sebagai berikut.

Sebelum mencari dan mengidentifikasi model ARIMA terbaik, perlu diketahui dahulu apakah model ARIMA yang ada perlu dibawa ke SARIMA atau tidak. Untuk itu, akan diperiksa plot ACF dan PACF pada deret waktu yang sudah dikenakan differensiasi orde pertama.



Gambar 4.3. Visualisasi ACF dan PACF Data Setelah Differensiasi Pertama

Sumber: Lampiran 1

Dari plot ACF dan PACF diatas, dapat diperhatikan bahwa tidak ada pola autokorelasi yang kuat secara periodik. Selain itu, hampir semua nilai autokorelasi untuk lag besar berada dalam *confidence interval* (CI). Oleh karena itu, dapat dipastikan data setelah terdiferensiasi tidak memiliki pola musiman.

Setelah deret waktu dipastikan tidak memiliki pola musiman, maka akan dilakukan spesifikasi model dengan mencari orde terbaik pada model ARIMA (p, d, q). Untuk mengidentifikasi orde komponen AR dan MA, akan dilakukan identifikasi kembali pada plot ACF dan PACF sebelumnya. Pada ACF, terdapat *spike* pada lag 1 dan lag 2. Begitu juga pada PACF, terdapat *spike* pada lag 1 dan lag 2. Akibatnya, dipilih $p = 2$ dan $q = 2$. Untuk itu, akan diajukan model ARIMA (2,1,2) yang dalam model matematika dapat ditulis sebagai berikut.

$$\nabla Y_t = \phi_1 \nabla Y_{t-1} + \phi_2 \nabla Y_{t-2} + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2}, \epsilon \sim IID(0, \sigma^2)$$

Dari model yang diajukan tersebut, akan dilakukan diagnostik model. Sebelum itu, model di-*fit* pada dataset dahulu dengan hasil sebagai berikut.

SARIMAX Results						
=====						
Dep. Variable:	Terakhir	No. Observations:	1096			
Model:	ARIMA(2, 1, 2)	Log Likelihood	-11759.033			
Date:	Tue, 10 Jun 2025	AIC	23528.066			
Time:	04:43:32	BIC	23553.058			
Sample:	0	HQIC	23537.523			
	- 1096					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	0.6454	0.113	5.718	0.000	0.424	0.867
ar.L2	-0.8810	0.101	-8.701	0.000	-1.079	-0.683
ma.L1	-0.6538	0.116	-5.617	0.000	-0.882	-0.426
ma.L2	0.8748	0.104	8.430	0.000	0.671	1.078
sigma2	1.204e+08	1.9e-09	6.33e+16	0.000	1.2e+08	1.2e+08
=====						
Ljung-Box (L1) (Q):	16.39	Jarque-Bera (JB):	937.92			
Prob(Q):	0.00	Prob(JB):	0.00			
Heteroskedasticity (H):	3.31	Skew:	0.09			
Prob(H) (two-sided):	0.00	Kurtosis:	7.53			
=====						
Warnings:						
[1] Covariance matrix calculated using the outer product of gradients (complex-step).						
[2] Covariance matrix is singular or near-singular, with condition number 1.47e+32. Standard errors may be unstable.						

Gambar 4.4. Ringkasan Hasil *Fitting* ARIMA (2,1,2)

Sumber: Lampiran 1

Dapat diperhatikan bahwa, meskipun semua parameter pada model telah signifikan ($p\text{-value} < 0.05$), perlu diperhatikan bahwa *warning* kedua mengatakan bahwa *standard error* kemungkinan tidak stabil. Nilai yang sangat besar (seperti 1.47e+32, yang berarti 1.47 diikuti oleh 32 angka nol) menunjukkan bahwa matriks tersebut sangat mendekati singular. Untuk itu, diperlukan transformasi log sedemikian sehingga nilai kovarians wajar dan tidak mendekati singular.


Dilakukan transformasi log dengan bantuan *library numpy* dan ditambahkan pada *dataframe* dengan algoritma sebagai berikut

```
df_resampled['Terakhir_log'] = np.log(df_resampled['Terakhir'])
```

Algoritma 4.1. Kode untuk Menambahkan Transformasi Log pada *Dataframe*

Sumber: Lampiran 1

Setelah dilakukan transformasi log, dilakukan diferensiasi kembali. Hasil diferensiasi kemudian divisualisasikan dalam plot ACF dan PACF pada **Gambar 4.5**.




Gambar 4.5. Visualisasi ACF dan PACF pada Data Setelah Diferensiasi

Sumber: Lampiran 1

Gambar di atas menunjukkan plot deret waktu pada data yang dikenakan transformasi log (sebelum serta sesudah diferensiasi sekali dan dua kali) beserta dengan plot ACF-nya. Dapat diperhatikan, diferensiasi orde pertama sudah cukup untuk membuat deret waktu memiliki mean yang terlihat konstan (tidak ada tren naik). Perlu menjadi perhatian, diferensiasi orde dua (atau lebih) dapat mengakibatkan data hasil diferensiasi yang *overconfidence* sehingga pemilihan dilakukan secara parsimoni,

Dengan cara yang serupa, akan dilakukan pengecekan plot ACF dan PACF pada data yang telah dikenakan transformasi log dan *first-order differencing*.



Gambar 4.6. Visualisasi Plot ACF dan PACF Setelah Diferensiasi

Sumber: Lampiran 1

Pada ACF, terdapat *spike* pada lag 1, lag 2 dan lag 3. Sedangkan, pada PACF terdapat *spike* pada lag 1 dan lag 2. Akibatnya, dipilih $p = 2$ dan $q = 3$. Untuk itu, akan diajukan model ARIMA (2,1,3) pada deret waktu yang dikenai transformasi log.

Dari model yang diajukan tersebut, akan dilakukan diagnostik model. Untuk itu, model di-*fit* pada dataset dahulu dengan hasil sebagai berikut.

SARIMAX Results						
=====						
Dep. Variable:	Terakhir_log	No. Observations:	1096			
Model:	ARIMA(2, 1, 3)	Log Likelihood	3620.653			
Date:	Tue, 10 Jun 2025	AIC	-7229.307			
Time:	04:48:52	BIC	-7199.315			
Sample:	0	HQIC	-7217.958			
	- 1096					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.L1	0.5483	0.180	3.048	0.002	0.196	0.901
ar.L2	0.1373	0.205	0.671	0.502	-0.264	0.539
ma.L1	-0.7559	0.179	-4.216	0.000	-1.107	-0.404
ma.L2	-0.1271	0.229	-0.555	0.579	-0.576	0.322
ma.L3	0.1622	0.049	3.279	0.001	0.065	0.259
sigma2	7.857e-05	2.42e-06	32.476	0.000	7.38e-05	8.33e-05
=====						
Ljung-Box (L1) (Q):	0.07	Jarque-Bera (JB):	185.91			
Prob(Q):	0.79	Prob(JB):	0.00			
Heteroskedasticity (H):	1.27	Skew:	0.23			
Prob(H) (two-sided):	0.02	Kurtosis:	4.96			
=====						
Warnings:						
[1] Covariance matrix calculated using the outer product of gradients (complex-step).						

Gambar 4.7. Ringkasan Hasil ARIMA(2,1,3) Data Tertransformasi

Sumber: Lampiran 1

Perlu diperhatikan, transformasi logaritma berhasil menangani *warning* kedua dengan standar deviasi yang sudah terkontrol. Model ARIMA (2,1,3) yang diestimasi menunjukkan bahwa sebagian besar parameter signifikan secara statistik, terutama AR(1), MA(1), dan MA(3), dengan $p\text{-value} < 0.05$. Nilai AIC dan BIC yang rendah menunjukkan model cukup baik. Namun, hasil Jarque-Bera

yang signifikan ($p\text{-value} < 0.05$) mengindikasikan bahwa residual tidak terdistribusi normal dan uji Heteroskedastisitas (H) juga signifikan ($p\text{-value} = 0.02 < 0.05$), menandakan adanya variasi varians residual (*ARCH effect*). Hal ini mendukung perlunya pemodelan volatilitas lanjutan menggunakan GARCH untuk menangkap dinamika variasi yang tidak ditangkap ARIMA. Namun, sebelum itu akan dicari model yang lebih parsimoni dengan pendekatan iteratif. Pencarian model baru ini juga dilakukan untuk menangani pelanggaran asumsi yang terjadi pada model sebelumnya.

Dengan mengiterasi p diantara 0 sampai 4, $d = 1$, dan q di antara 0 sampai 4, akan ditentukan model terbaik dengan mempertimbangkan skor AIC, BIC, log likelihood, jumlah parameter yang signifikan, dan lainnya. Hasil 7 *fitting* terbaik model dapat dilihat pada **Tabel 4.3** berikut.

Tabel 4.3. Hasil Iterasi ARIMA(p,d,q) dengan Parameter Yang Disesuaikan

Order	AIC	<i>Ljung-box p-value</i>	Parameter Signfikan	Banyak Parameter
(3,1,4)	-7214,8292	1,000	7	8
(4,1,4)	-7219,8885	1,000	6	9
(1,1,3)	-7231,1429	1,000	4	5
(2,1,3)	-7229,3065	1,000	4	6
(0,1,4)	-7228,4240	1,000	4	5
(0,1,3)	-7227,1781	1,000	4	4
(2,1,0)	-7226,6502	1,000	3	3

Sumber: Lampiran 1

Meskipun jika diperhatikan dari metrik seperti AIC, BIC, dan lainnya model ARIMA (3,1,4) adalah yang paling direkomendasikan, akan tetapi model ARIMA(0,1,3) dianggap lebih baik karena alasan parsimoni dan semua parameter yang signifikan. Berikut adalah rincian hasil *fitting* model ARIMA(0,1,3).

SARIMAX Results						
=====						
Dep. Variable:	Terakhir_log	No. Observations:	1096			
Model:	ARIMA(0, 1, 3)	Log Likelihood	3617.589			
Date:	Tue, 10 Jun 2025	AIC	-7227.178			
Time:	05:01:50	BIC	-7207.184			
Sample:	0	HQIC	-7219.613			
	- 1096					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ma.L1	-0.2077	0.022	-9.360	0.000	-0.251	-0.164
ma.L2	-0.1032	0.023	-4.460	0.000	-0.149	-0.058
ma.L3	0.0786	0.025	3.160	0.002	0.030	0.127
sigma2	7.904e-05	2.43e-06	32.492	0.000	7.43e-05	8.38e-05
=====						
Ljung-Box (L1) (Q):			0.03	Jarque-Bera (JB):		186.04
Prob(Q):			0.86	Prob(JB):		0.00
Heteroskedasticity (H):			1.26	Skew:		0.26
Prob(H) (two-sided):			0.03	Kurtosis:		4.95
=====						

Gambar 4.8. Ringkasan Hasil ARIMA (0,1,3)

Sumber: Lampiran 1

Kondisi ini menunjukkan bahwa meskipun model ARIMA mampu menangkap struktur dependensi mean, fluktuasi volatilitas residual belum sepenuhnya tertangkap oleh model. Oleh karena itu, untuk mengatasi masalah perubahan varians dari waktu ke waktu, diperlukan pengembangan model lanjutan seperti ARIMA-GARCH. Model ini memungkinkan kita untuk tetap menangkap pola nilai tengah dengan ARIMA, sambil mengakomodasi dinamika volatilitas melalui komponen GARCH. Akibatnya, akan dihasilkan model yang lebih stabil dan realistis dalam merepresentasikan sifat data keuangan atau data deret waktu dengan volatilitas tinggi. Berikut model matematis dari ARIMA (0,1,3) dengan penaksiran parameter yang dihasilkan oleh *software python*.

$$\nabla Y_t = \epsilon_t - 0,2077\epsilon_{t-1} - 0,1032\epsilon_{t-2} + 0,0786\epsilon_{t-3}$$

4.2. Pemodelan GARCH

Berdasarkan hasil *fitting* model ARIMA (0,1,3) pada proses runtun waktu Terakhir_log terlihat bahwa meskipun model mampu menangkap struktur dependensi mean, fluktuasi volatilitas residual belum sepenuhnya tertangkap oleh model. Oleh karena itu, untuk mengakomodasi dinamika volatilitas diperlukan pemodelan GARCH (*Generalized Autoregressive Conditional Heteroscedasticity*).

Didefinisikan

$$r_t = \log(X_t) - \log(X_{t-1}) = \log\left(\frac{X_t}{X_{t-1}}\right)$$


dengan keterangan sebagai berikut:

r_t : log-return pada X_t

X_t : harga emas pada waktu t

X_{t-1} : harga emas pada waktu $t - 1$


Berikut merupakan visualisasi dari r_t dan r_t^2 .



Gambar 4.9. Visualisasi r_t dan r_t^2

Sumber: Lampiran 1


Dari visualisasi di atas terlihat bahwa *log return* r_t sudah stasioner dikarenakan *mean*-nya 0. Namun, dikarenakan $Var(r_t) \approx E[r_t^2]$ dan *squared returns* r_t^2 merupakan proksi dari volatilitas maka lonjakan pada r_t^2 menunjukkan volatilitas tinggi pada titik waktu tersebut. Selanjutnya, akan diperiksa plot ACF dari r_t dan r_t^2 .



Gambar 4.10 Visualisasi ACF dari r_t dan r_t^2

Berdasarkan plot ACF dari r_t terlihat bahwa hanya sampai lag-2 yang signifikan; sisanya berada dalam batas kepercayaan. Ini menandakan hanya terdapat sedikit autokorelasi negatif signifikan dalam return itu sendiri dan ini merupakan hal umum

untuk seri *log-return*. Lalu, berdasarkan plot ACF dari r_t^2 terlihat bahwa banyak lag yang menunjukkan autokorelasi positif signifikan. Ini menandakan *squared returns* memiliki pola ketergantungan. Dengan kata lain, ada indikasi kuat bahwa terdapat heteroskedastisitas (variansi yang tidak konstan) - atau efek ARCH. Variabilitas *return* berubah-ubah dari waktu ke waktu meskipun nilai *return*-nya tidak berkorelasi. Lalu, akan dibentuk histogram dari r_t dan dicari nilai *skewness* dan *kurtosis* dari r_t .



Gambar 4.11. Plot Histogram dari r_t

Sumber: Lampiran 1

Tabel 4.4. Nilai *Skewness* dan *Kurtosis* dari r_t

Skewness	Kurtosis
0,0898	1,6852

Sumber: Lampiran 1

Terlihat bahwa bentuk histogram tampak mendekati simetris dan sedikit skew ke kanan yang sesuai dengan nilai *skewness* yang mendekati 0. Ini menunjukkan bahwa distribusi mendekati normal. Lalu, untuk nilai *kurtosis* 1,6852 menunjukkan distribusi dengan kurva yang lebih pendek dan *light-tailed* dibanding dengan distribusi normal (*kurtosis* normal = 3). Selanjutnya, akan diperiksa apakah residual dari model ARIMA mengandung efek ARCH atau ekuivalen mengetahui eksistensi heteroskedastisitas bersyarat dalam residual. Residual didefinisikan sebagai:

$$e_t = y_t - \hat{y}_t$$

dengan keterangan sebagai berikut:

- e_t : residual

y_t : nilai observasi aktual

$\hat{y}_t$: nilai prediksi dari model ARIMA

Residual idealnya bersifat white noise: tidak berkorelasi, variansi konstan, dan distribusi normal. Namun, pada data ini, variansi residual berubah-ubah seiring waktu yang mengindikasikan terdapat efek ARCH. Untuk mengujikannya, dilakukan pengujian efek ARCH menggunakan *Lagrange Multiplier Test*. Uji ini berdiri dengan hipotesis sebagai berikut. Hipotesis:

H_0 : Tidak ada efek ARCH (variansi residual konstan/homoskedastisitas)

H_1 : Terdapat efek ARCH (variansi berubah bergantung pada masa lalu)


Berdasarkan hipotesis tersebut, uji efek ARCH menguji apakah $Var(e_t|F_{t-1})$ bergantung pada nilai residual masa lalu. Dengan bantuan *software python*, didapat *output* uji efek ARCH sebagai berikut.

Tabel 4.5. Hasil Uji *Lagrange Multiplier*

LM Statistic	LM p-value	F-Statistic	F p-value
141,4756	0,0000	16,1019	0,0000

Sumber: Lampiran 1

Dari hasil **Tabel 4.5**, dikarenakan $LM p - value < 0,05$, maka H_0 ditolak. Artinya, terdapat efek ARCH yang signifikan. Oleh karena itu, model ARIMA saja tidak cukup, diperlukan model GARCH untuk menangkap volatilitas pada data. Selanjutnya, akan dibentuk plot untuk residual.




Gambar 4.12. Plot Residual Model ARIMA

Sumber: Lampiran 1

Pada **Gambar 4.12**, plot residual memperlihatkan bagaimana fluktuasi residual berubah-ubah dari waktu ke waktu. Terlihat jelas adanya *volatility clustering*, yakni

return kecil cenderung diikuti dengan *return* kecil dan *return* besar cenderung diikuti dengan *return* besar – meskipun tanda berubah-ubah. Dari hal tersebut, diperiksa plot ACF dari kuadrat residual model ARIMA.



Gambar 4.13. Visualisasi ACF dari Kuadrat Residual Model ARIMA

Sumber: Lampiran 1

Nilai ACF dari kuadrat residual signifikan di beberapa lag awal, terlihat dari titik-titik yang berada di luar batas biru (interval kepercayaan). Ini menunjukkan adanya autokorelasi dalam variansi residual dan masih terdapat pola heteroskedastisitas dalam residual ARIMA sehingga model ARIMA saja tidak cukup, perlu di *fitting* model GARCH yang sesuai. Akan di *fitting* model volatilitas paling umum dalam pemodelan data finansial yaitu GARCH (1,1). Berikut hasil *fitting* model GARCH(1,1):

```


Constant Mean - GARCH Model Results
=====
Dep. Variable:          r_t      R-squared:          0.000
Mean Model:             Constant Mean  Adj. R-squared:      0.000
Vol Model:              GARCH      Log-Likelihood:    3660.38
Distribution:           Normal     AIC:              -7312.76
Method:                Maximum Likelihood  BIC:            -7292.76
                                     No. Observations:    1095
Date:                  Tue, Jun 10 2025  Df Residuals:      1094
Time:                  05:05:30          Df Model:          1
                                     Mean Model
=====
              coef    std err          t      P>|t|      95.0% Conf. Int.
-----
mu           4.3797e-04  1.040e-05    42.123    0.000 [4.176e-04,4.583e-04]
Volatility Model
=====
              coef    std err          t      P>|t|      95.0% Conf. Int.
-----
omega        8.3239e-06  1.238e-10   6.723e+04    0.000 [8.324e-06,8.324e-06]
alpha[1]      0.2000    3.286e-02     6.086  1.156e-09 [ 0.136, 0.264]
beta[1]       0.7000    3.015e-02    23.214  3.259e-119 [ 0.641, 0.759]
=====
Covariance estimator: robust

```

Gambar 4.14. Ringkasan Model GARCH(1,1)

Sumber: Lampiran 1

Model GARCH(1,1) yang diterapkan menunjukkan bahwa rata-rata *return* adalah sekitar 0,0438% per periode, dan nilai ini signifikan secara statistik, mengindikasikan bahwa *return* rata-rata tidak nol. Selanjutnya, pada persamaan volatilitas, semua parameter terestimasi secara signifikan. Konstanta dasar variansi (ω) terestimasi sekitar $8,32 \times 10^{-6}$. Parameter α_1 sebesar 0,2000 menunjukkan bahwa guncangan atau *shocks* pada periode sebelumnya memiliki dampak yang signifikan terhadap volatilitas saat ini. Sementara itu, parameter β_1 sebesar 0,7000 menunjukkan bahwa volatilitas periode sebelumnya juga memiliki dampak yang kuat dan signifikan terhadap volatilitas saat ini. Penjumlahan $\alpha_1 + \beta_1$ sebesar 0,9000 mengindikasikan adanya persistensi volatilitas yang tinggi, sebuah karakteristik umum yang sering ditemukan pada data *return* aset keuangan. Secara keseluruhan, model GARCH(1,1) ini berhasil menangkap dinamika volatilitas data secara statistik. Selanjutnya, akan dilakukan *plotting standardized residuals* dan *annualized conditional volatility*.




Gambar 4.15. Visualisasi *Standardized Residuals* dan *Annualized Conditional Volatility*

Sumber: Lampiran 1


Plot volatilitas menunjukkan kluster volatilitas yang jelas, di mana periode volatilitas tinggi dan rendah bergantian, mengonfirmasi keberhasilan model GARCH dalam menangkap fenomena ini. Selain itu, level volatilitas keseluruhan juga bervariasi seiring waktu, dan model GARCH tampak merespon *shocks* dalam data dengan meningkatkan estimasi volatilitas, seperti yang terlihat dari korelasi puncak pada plot volatilitas dengan lonjakan pada *standardized residuals*.

Selanjutnya, diperiksa plot ACF dari *Standardized Residuals* dan *Standardized Residuals Squared*.



Gambar 4.16. Plot ACF dari *Standardized Residuals*

Sumber: Lampiran 1



Gambar 4.16. Plot ACF dari *Standardized Residuals Squared*

Sumber: Lampiran 1


ACF dari *standardized residuals squared* sudah merupakan *white noise*, tetapi ACF *standardized residuals* nya masih menangkap pola. Selanjutnya, dilakukan uji Ljung-Box lagi dan didapat hasil sebagai berikut.

Tabel 4.6. Hasil Uji Ljung-Box pada *Standardized Residuals*

	Statistik Uji	<i>p-value</i>
Standardized Residuals	51,780262	0,000123
Standardized Residuals Squared	18,301748	0,567538

Sumber: Lampiran 1

Berdasarkan hasil uji Ljung-Box di atas, GARCH(1,1) belum cukup baik dalam menangkap mean, maka perlu ditentukan meannya mengikuti pola apa. Selanjutnya, masuk ke tahap *tweaking* GARCH untuk mendiagnosis model GARCH dan dibentuk plot PACF dari r_t .



Gambar 4.17. Plot PACF pada r_t
Sumber: Lampiran 1

Dengan melihat PACF dari residual ARIMA, mean residual signifikan pada lag - 2. Oleh karena itu, perlu dilakukan penyesuaian mean pada parameter GARCH. Diperhatikan bahwa, perlu didefinisikan jenis mean, yakni AR, dan di lag mana mean tersebut signifikan. Berikut merupakan kode yang sudah disesuaikan.

```
model_garch1 = arch_model(df_resampled['r_t'].dropna(), mean='AR', lags=2,
vol='GARCH', p=1, q=1)
```


Algoritma 4.2. Kode Penyesuaian Mean pada GARCH

Sumber: Lampiran 1

Selanjutnya, model akan di *fitting* dengan model yang mampu menangkap dinamika *return* dan volatilitas data harga emas secara signifikan.

```
MODEL SUMMARY:
AR - GARCH Model Results
=====
Dep. Variable:      r_t      R-squared:      0.057
Mean Model:        AR      Adj. R-squared:    0.055
Vol Model:         GARCH    Log-Likelihood:    3680.57
Distribution:      Normal    AIC:        -7349.14
Method:           Maximum Likelihood    BIC:        -7319.16
No. Observations:  1093
Date:              Tue, Jun 10 2025    Df Residuals:  1090
Time:              05:06:55            Df Model:      3
Mean Model
=====
coef    std err      t      P>|t|      95.0% Conf. Int.
-----
Const    6.3809e-04  4.193e-05    15.220  2.620e-52  [5.559e-04, 7.203e-04]
r_t[1]   -0.2128  3.580e-02   -5.944  2.778e-09  [-0.283, -0.143]
r_t[2]   -0.1552  3.563e-02   -4.357  1.321e-05  [-0.225, -8.539e-02]
Volatility Model
=====
coef    std err      t      P>|t|      95.0% Conf. Int.
-----
omega    1.5716e-06  3.805e-12   4.131e+05  0.000  [1.572e-06, 1.572e-06]
alpha[1]  0.1000  2.612e-02    3.829  1.289e-04  [4.881e-02, 0.151]
beta[1]   0.8800  2.502e-02   35.176  4.687e-271  [ 0.831, 0.929]
Covariance estimator: robust
```

Gambar 4.18. Ringkasan GARCH (1,1) Setelah Penyesuaian
Gambar 4.18. Hasil *Fitting* Model GARCH
Sumber: Lampiran 1



Gambar 4.19. Visualisasi Hasil Model Diagnostik
Sumber Lampiran 1

Tabel 4.7. Hasil Ljung-Box Setelah Penyesuaian

	Statistik Uji	<i>p-value</i>
Standardized Residuals (lag 10)	8,72206	0,558669
Standardized Residuals Squared (lag 10)	15.432696	0.117065

Sumber Lampiran 1

Berdasarkan hasil diagnostik, model ARIMA(0,1,3)-GARCH(1,1) menunjukkan performa yang baik dalam menangkap dinamika data. Pola residual yang acak serta tidak adanya autokorelasi maupun efek ARCH yang tersisa (ditunjukkan oleh nilai $p > 0.05$ pada uji Ljung-Box) menandakan bahwa model telah berhasil menjelaskan struktur mean dan varians. Visualisasi histogram dan Q-Q plot residual juga menunjukkan distribusi yang mendekati normal, meskipun terdapat sedikit deviasi di bagian ekor. Secara keseluruhan, model ini dapat dianggap valid dan sesuai untuk keperluan peramalan return serta volatilitas data keuangan.

BAB 5

KESIMPULAN

5.1. Kesimpulan

Berdasarkan hasil estimasi yang telah dilakukan, model ARIMA(0,1,3)-GARCH(1,1) terbukti sebagai pendekatan yang tepat dalam menangkap dinamika return dan volatilitas dari data yang dianalisis. Pada sisi mean equation, meskipun model ARIMA tidak memiliki komponen *autoregressive* (AR) secara eksplisit dalam struktur utamanya, hasil estimasi menunjukkan bahwa lag hingga orde ketiga dari error term memberikan kontribusi signifikan terhadap pembentukan return saat ini. Hal ini menunjukkan bahwa terdapat autokorelasi jangka pendek dalam pergerakan return yang perlu diperhitungkan untuk menghasilkan model yang akurat.

Di sisi lain, variance equation dari model GARCH memperlihatkan bahwa parameter $\alpha[1]$ dan $\beta[1]$ signifikan, dengan $\beta[1]$ bernilai 0.88, yang mengindikasikan adanya efek volatilitas yang persisten atau volatility clustering, di mana kejutan volatilitas pada masa lalu memiliki pengaruh jangka panjang terhadap volatilitas masa depan. Selain itu, nilai omega yang sangat kecil namun signifikan menandakan bahwa model memiliki kestabilan jangka panjang dalam memodelkan varians return, tanpa mengabaikan fluktuasi minor yang mungkin terjadi. Uji diagnostik residual turut memperkuat keandalan model ini. Uji Ljung-Box tidak menunjukkan adanya autokorelasi tersisa, baik pada residual maupun squared residual, yang mengindikasikan bahwa model telah menangkap dinamika temporal secara memadai.

Sementara itu, hasil uji ARCH menunjukkan tidak terdapat heteroskedastisitas tersisa, sehingga struktur varians dalam data sudah berhasil dijelaskan secara menyeluruh oleh model GARCH yang digunakan. Secara keseluruhan, kombinasi model ARIMA(0,1,3) untuk mean dan GARCH(1,1) untuk varians dinilai mampu merepresentasikan karakteristik penting dari data return secara menyeluruh, baik dalam aspek nilai tengah maupun fluktuasi. Dengan performa statistik yang baik dan interpretasi parameter yang mendalam, model ini layak dijadikan dasar dalam analisis risiko, peramalan volatilitas, serta pengambilan keputusan dalam konteks manajemen portofolio atau strategi investasi jangka pendek.

DAFTAR PUSTAKA

- Mutiara, A. Analisis prediksi inflasi di indonesia: perbandingan model arima-garch dan long short term memory (lstm) (Bachelor's thesis, Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta).
- Sari, H. R., Wahyuningsih, S., & Siringoringo, M. (2024). Indonesia Gold Price Forecasting Using ARIMA Model (0, 1, 1)-GARCH (1, 0). *EKSPONENSIAL*, 15(1), 1-10.
- Yang, X. (2019, January). The prediction of gold price using ARIMA model. In 2nd International Conference on Social Science, Public Health and Education (SSPHE 2018) (pp. 273-276). Atlantis Press.
- Zili, Arman Haqqi Anna, Derick Hendri, and Selly Anastassia Amellia Kharis. "Peramalan harga saham dengan model hybrid arima-Garch dan metode Walk Forward." *Jurnal Statistika Dan Aplikasinya* 6.2 (2022): 341-354.